INFORME TÉCNICO: SISTEMA PREDICTIVO Y PRESCRIPTIVO DE ABANDONO DE CLIENTES (CHURN B2B) BAJO METODOLOGÍA CRISP-DM

Empresa: DataCloud Solutions
Autoras: Emilys López Pérez & Kerelys Zambrano Villegas
Repositorio GitHub: github.com/elopezp3-hash/churn_data_science_project
Fecha: Octubre de 2026
Versión: 2.4 (Release Candidate)

RESUMEN EJECUTIVO

El presente informe documenta el desarrollo, validación y despliegue del sistema predictivo y prescriptivo de abandono de clientes (Churn B2B) para **DataCloud Solutions**, implementado bajo la metodología estándar **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*). El objetivo primordial del proyecto es mitigar la pérdida de ingresos recurrentes (ARR/MRR) identificando a los clientes corporativos en riesgo de cancelación antes de que hagan efectiva su salida.

El pipeline integra un modelo de clasificación supervisada basado en **Random Forest Classifier** optimizado para maximizar el *Recall* ($\tau = 0.35$), una segmentación no supervisada mediante **K-Means ($K = 3$)** para tipificar el comportamiento de los usuarios, y un módulo de métricas sintéticas interactivas (C_{min} y A_{req}) desplegado mediante un Dashboard interactivo en **Streamlit**.

FASE 1: ENTENDIMIENTO DEL NEGOCIO (BUSINESS UNDERSTANDING)

1.1. Contexto Organizacional y Problema Central

DataCloud Solutions opera bajo un modelo de negocio *Software as a Service* (SaaS) y servicios de infraestructura Cloud B2B. En este modelo, el costo de adquisición de un nuevo cliente (CAC) supera significativamente el costo de retención de un cliente activo (CRC). Específicamente, se estima que:

$$CAC \approx 5 \times CRC$$

La pérdida imprevista de cuentas corporativas genera una contracción directa del margen operativo y reduce el valor del cliente en el tiempo (*Customer Lifetime Value* - LTV).

1.2. Función de Costo de Clasificación Asimétrica

En el contexto B2B, la matriz de costos de clasificación no es simétrica:

- **Falso Negativo (FN):** Un cliente en riesgo real de churn es clasificado como leal. La empresa no interviene y pierde el contrato (LTV).
- **Falso Positivo (FP):** Un cliente leal es clasificado erróneamente como en riesgo. La empresa invierte en una campaña de fidelización o descuento no requerido ($C_{fidelizacion}$).

Dado que $C_{FN} \gg C_{FP}$, la función de pérdida del negocio $L(Y, \hat{Y})$ se expresa formalmente como:

$$L(Y, \hat{Y}) = C_{FN} \cdot I(Y = 1, \hat{Y} = 0) + C_{FP} \cdot I(Y = 0, \hat{Y} = 1)$$

Donde $I(\cdot)$ es la función indicadora, $Y = 1$ representa el evento de Churn, y $\hat{Y} = 1$ representa la predicción positiva. Por ende, la optimización técnica del modelo debe enfocarse explícitamente en la **maximización del Recall (Sensibilidad)**:

$$\text{Recall} = \frac{TP}{TP + FN}$$

FASE 2: ENTENDIMIENTO Y PREPARACIÓN DE LOS DATOS (DATA PREPARATION)

2.1. Ingestion y Estructura de Datos

El dataset contiene información histórica de interacciones, métricas de consumo y datos transaccionales de clientes corporativos. Las variables de entrada originales comprenden:

- **Numéricas:** `Edad`, `Antiguedad_Meses`, `Soporte_Tickets`, `Uso_Diario_Min`, `Monto_Mensual`.
- **Categorización y Demografía:** `Genero`, `Region`.
- **Variable Objetivo:** `Churn` ($\in \{0, 1\}$).

2.2. Ingeniería de Características (Feature Engineering)

Para capturar la fricción operativa y la ineficiencia económica percibida por los clientes, se formalizaron dos variables sintéticas clave:

A. Costo por Minuto Percibido (C_{min})

Representa el costo efectivo que el cliente paga por cada minuto de uso real del servicio durante un período mensual (30 días):

$$C_{min} = \frac{\text{Monto_Mensual}}{\text{Uso_Diario_Min} \times 30}$$

Si $\text{Uso_Diario_Min} = 0$, se asigna NaN y se imputa formalmente mediante la mediana de la población para evitar divisiones por cero. Un valor elevado de C_{min} indica un bajo retorno percibido de la inversión por parte del cliente corporativo.

B. Indicador Binario de Atención Requerida (A_{req})

Modela el umbral de tolerancia del cliente frente a incidentes técnicos. Se define mediante la función escalón:

$$A_{req} = \begin{cases} 1, & \text{si Soporte_Tickets} > 5 \\ 0, & \text{si Soporte_Tickets} \leq 5 \end{cases}$$

La activación de $A_{req} = 1$ señala una saturación de la mesa de ayuda y exige una intervención humana inmediata priorizada por un ejecutivo de *Customer Success*.

FASE 3: MODELADO Y EVALUACIÓN SUPERVISADA (MODELING & EVALUATION)

3.1. Selección de Arquitectura de Aprendizaje

Se seleccionó la arquitectura **Random Forest Classifier** debido a su capacidad intrínseca para capturar relaciones no lineales y complejas interacciones entre variables sin asumir supuestos rígidos de normalidad.

Un Random Forest representa un ensamble de B árboles de decisión $\{T_1(x), T_2(x), \ldots, T_B(x)\}$. La predicción probabilística agregada para la clase de riesgo $Y = 1$ viene dada por:

$$P(Y = 1|X = x) = \frac{1}{B} \sum_{b=1}^{B} P_b(Y = 1|X = x)$$

Para balancear el desbalance de clases nativo de los datos de churn, se aplicó la ponderación de pesos inversamente proporcional a la frecuencia de clase:

$$w_j = \frac{N}{K \cdot n_j}$$

Donde N es el total de muestras, $K = 2$ es el número de clases, y n_j es el número de observaciones en la clase j.

3.2. Calibración Operativa del Umbral ($\tau = 0.35$)

Por defecto, los clasificadores aplican un umbral estándar de decisión $\tau_0 = 0.50$. Sin embargo, en virtud de la asimetría de costos ($C_{FN} \gg C_{FP}$), se desplazó operativamente el umbral de decisión a:

$$\tau^* = 0.35$$

La regla de clasificación final aplicada en inferencia es:

$$\hat{Y} = \begin{cases} 1 (\text{Alto Riesgo}), & \text{si } P(Y = 1|X) \geq 0.35 \\ 0 (\text{Bajo Riesgo}), & \text{si } P(Y = 1|X) < 0.35 \end{cases}$$

3.3. Métricas de Evaluación Obtenidas

Evaluación en el conjunto de prueba ($N_{test} = 200$, 20% retenido con estratificación):

- **Recall ($\tau = 0.35$): 85.0%** — Garantiza la detección anticipada de la vasta mayoría de clientes en riesgo.
- **Precision ($\tau = 0.35$): 68.0%** — Mantiene una tasa aceptable de falsas alarmas.
- **F1-Score: 0.756** — Demuestra un desempeño armónico sólido.
- **ROC-AUC: 0.892** — Alta capacidad de discriminación probabilística global.

FASE 4: SEGMENTACIÓN NO SUPERVISADA Y PERFILAMIENTO (CLUSTERING)

4.1. Algoritmo K-Means ($K = 3$)

Con el propósito de caracterizar el perfil comportamental de los clientes para la prescripción de estrategias diferenciadas, se aplicó el algoritmo **K-Means** sobre el espacio de características numéricas estandarizadas Z:

$$Z_j = \frac{X_j - \mu_j}{\sigma_j}$$

El objetivo de optimización de K-Means consiste en minimizar la suma de cuadrados dentro de los clusters (WCSS):

$$\arg\min_{\mathbf{S}} \sum_{i=1}^{K} \sum_{\mathbf{x} \in S_i} \|\mathbf{x} - \boldsymbol{\mu}_i\|^2$$

Donde $K = 3$ fue determinado mediante el método del codo (*Elbow Method*) y el coeficiente de silueta (*Silhouette Score*).

4.2. Perfiles de Clusters Identificados

1. **Cluster 0 — Clientes Saludables (Bajo Riesgo):**
   - Elevada antigüedad, alto uso diario promedio, bajo volumen de tickets.
   - *Estrategia:* Mantenimiento y programas de Upselling / Cross-selling.
2. **Cluster 1 — Clientes en Fricción Crítica ($A_{req} = 1$):**
   - Registran más de 5 tickets por trimestre. Alta tasa de incidentes sin resolver.
   - *Estrategia:* Asignación inmediata de un Customer Success Manager (CSM) dedicado para contención técnica.
3. **Cluster 2 — Clientes Ineficientes / Inactivos (C_{min} Alto):**
   - Alto cobro mensual combinado con bajísimo consumo de la plataforma.
   - *Estrategia:* Despliegue de capacitaciones, programas de re-onboarding y optimización de uso.

FASE 5: EXPLICABILIDAD (XAI) Y ÉTICA EN IA

5.1. Importancia por Permutación e Valores SHAP

Para evitar la opacidad del modelo (*Black Box*), se implementaron técnicas de Explicabilidad Agnostica (XAI). La importancia global de las características revela que los principales factores de riesgo son:

1. `Soporte_Tickets` **/ A_{req}:** Factor dominante en la probabilidad de churn.
2. `Uso_Diario_Min`**:** Relación inversamente proporcional con la probabilidad de abandono.
3. `Costo_Por_Minuto` **(C_{min}):** Factor económico clave para cuentas de alto valor.

5.2. Auditoría de Equidad y Sesgo Demográfico

Se realizó una auditoría exploratoria para asegurar que el modelo no genere discriminación sistemática por variables sensibles demográficas (`Genero`, `Region`). Se evaluó la paridad demográfica en la tasa de falsos positivos (FPR) y falsos negativos (FN), verificando que las fluctuaciones en las métricas no superan el margen del 5%, cumpliendo con los estándares éticos de equidad en IA.

FASE 6: ARQUITECTURA DE DESPLIEGUE Y OPERACIONALIZACIÓN

El sistema se desplegó en producción utilizando **Streamlit** en un entorno Python gestionado.