Informe Técnico y Justificación Metodológica

Proyecto: Sistema Predictivo y Prescriptivo de Churn B2B — DataCloud Solutions
Metodología: CRISP-DM
Autor: Equipo de Ciencia de Datos

---

1. Comprensión del Negocio (Business Understanding)

1.1 Formulación del Problema

En el modelo B2B de *DataCloud Solutions*, la pérdida de un cliente (*churn*) implica una reducción directa del ingreso recurrente mensual (MRR). La adquisición de nuevos clientes requiere una inversión en marketing y ventas significativamente superior a la retención de un cliente existente.

1.2 Matriz de Costos y Función de Pérdida

Desde la perspectiva de teoría de decisiones, clasificar a un cliente requiere balancear dos tipos de errores:

- **Falso Positivo (FP):** Predecir que un cliente abandonará cuando en realidad se quedaría. Esto genera un costo de intervención innecesario (C_{FP}).
- **Falso Negativo (FN):** Predecir que un cliente es leal cuando en realidad abandonará. Esto genera la pérdida del valor de vida del cliente (C_{FN}).

Dado que $C_{FN} \gg C_{FP}$, la métrica de optimización principal seleccionada es el **Recall (Sensibilidad)**:

$$\text{Recall} = \frac{TP}{TP + FN}$$

Un alto *Recall* garantiza la detección de la gran mayoría de clientes en riesgo de abandono.

---

2. Comprensión y Preparación de Datos (Data Understanding & Preparation)

2.1 Feature Engineering (Ingeniería de Características)

Se diseñaron variables derivadas para capturar patrones de comportamiento no lineales:

1. **Costo Por Minuto (C_{min}):** Relación de eficiencia del valor del contrato respecto al consumo real.

$$C_{min} = \frac{\text{Monto_Mensual}}{\text{Uso_Diario_Min} \times 30}$$

2. **Atención Requerida (A_{req}):** Variable binaria para clientes con alta fricción operativa en soporte técnico.

$$A_{req} = \mathbb{I}(\text{Soporte_Tickets} > 5)$$

2.2 Tratamiento de Variables Categoricas y Escalamiento

- **Columnas Numéricas:** Imputación por mediana + Escalamiento robusto ($RobustScaler$) para mitigar el efecto de valores atípicos (*outliers*).
- **Columnas Categóricas:** Imputación por la moda + Codificación $OneHotEncoder(handle_unknown =' ignore')$ para preservar la independencia de categorías.

---

3. Modelado y Justificación Matemática (Modeling)

3.1 Clasificación Supervisada: Random Forest

Se seleccionó un ensamble de árboles de decisión (*Random Forest*) por su capacidad de capturar interacciones no lineales entre las variables y su resistencia al sobreajuste (*overfitting*).

La predicción final para una observación x en un ensamble de B árboles se expresa como la promediación de las probabilidades individuales:

$$\hat{P}(Y=1|x) = \frac{1}{B}\sum_{b=1}^{B} P_b(Y=1|x)$$

La clasificación binaria adopta un umbral probabilístico predeterminado de $\tau = 0.50$:

$$\hat{y} = \begin{cases} 1 & \text{si } \hat{P}(Y=1|x) \geq \tau \\ 0 & \text{en otro caso} \end{cases}$$

3.2 Clustering No Supervisado: K-Means

Para el perfilamiento de usuarios y la asignación de acciones prescriptivas, se empleó la técnica de aglomeración K-Means sobre las variables estandarizadas. El algoritmo busca minimizar la suma de cuadrados intra-cluster (Inercia, J):

$$J = \sum_{k=1}^{K} \sum_{x_i \in C_k} ||x_i - \mu_k||^2$$

donde μ_k representa el centroide del cluster C_k.

---

4. Evaluación y Explicabilidad (Evaluation & Governance)

4.1 Explicabilidad Global e Individual mediante Valores SHAP

Basado en la teoría de juegos cooperativos, el valor SHAP (ϕ_i) asigna a cada variable i un peso proporcional a su contribución marginal al resultado del modelo:

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} \Big(f(S \cup \{i\}) - f(S) \Big)$$

Esto permite auditar las predicciones ante el usuario final sin tratar al modelo de Random Forest como una "caja negra".

4.2 Auditoría Exploratoria de Equidad (Fairness Audit)

Con el objetivo de garantizar la no discriminación algorítmica por factores geográficos o demográficos protegidos (ej. `Genero`, `Region`), se monitorean de forma continua las métricas de disparo positivo y desempeño grupal:

$$\text{Disparidad de Recall} = \frac{\text{Recall}_{\text{grupo}}}{\text{Recall}_{\text{global}}}$$

Se exige que ningún grupo demográfico presente un *Recall* significativamente inferior al promedio del sistema.

---

5. Despliegue y Arquitectura de Software (Deployment)

La solución fue empaquetada e integrada en un pipeline automatizado en Python (`run_pipeline.py`) que genera los siguientes artefactos serializados:

- `modelo_churn.joblib`: Modelo clasificador entrenado.
- `modelo_clustering.joblib`: Pipeline de segmentación K-Means.
- `auditoria_equidad.csv` y `shap_importancia_global.csv`: Reportes de gobernanza.

La interfaz de usuario fue construida utilizando **Streamlit** en un entorno oscurecido (*Dark Mode*), ofreciendo inferencia en tiempo real para la toma de decisiones por analistas de retención humana.