Informe Técnico y Justificación Metodológica End-to-End

Proyecto: Sistema Predictivo y Prescriptivo de Churn B2B — DataCloud Solutions
Metodología: CRISP-DM (Fases 1 a 5)
Autoras: Emilys López Pérez & Kerelys Zambrano Villegas
Repositorio GitHub: https://github.com/elopezp3-hash/churn_data_science_project

---

1. Fase 1: Fundamentos de Ciencia de Datos (Business & Data Understanding)

1.1 Formulación del Problema bajo CRISP-DM

En el modelo de negocio B2B de *DataCloud Solutions*, la pérdida no detectada de clientes (*churn*) impacta de forma directa el ingreso recurrente mensual (MRR). La adquisición de un nuevo cliente corporativo requiere costos de marketing y ventas sustancialmente superiores a los de retención. El objetivo central es construir un modelo predictivo binario de clasificación ($Y = 1$ para riesgo de Churn) integrado a un módulo prescriptivo no supervisado para recomendar acciones tácticas antes de la cancelación.

1.2 Matriz de Costos, Función de Pérdida Financiera y Métrica Principal

Desde la perspectiva de la teoría de decisiones financieras, evaluamos la asimetría de costos entre los errores de clasificación:

- **Falso Positivo (FP):** Predecir abandono cuando el cliente es leal. Conlleva el costo de una campaña o descuento innecesario (C_{FP}).
- **Falso Negativo (FN):** Predecir lealtad cuando el cliente cancelará. Conlleva la pérdida total del valor de vida del cliente (LTV, C_{FN}).

La Función de Pérdida Financiera Global (L_{Total}) se expresa como:

$$L_{Total} = C_{FN} \cdot FN + C_{FP} \cdot FP$$

Dado que $C_{FN} \gg C_{FP}$ ($LTV \gg \text{Costo de Campaña}$), la métrica técnica priorizada es el **Recall (Sensibilidad)** sobre el *Accuracy* y el *Precision*. El *Accuracy* se descarta debido a que el desbalanceo de clases genera un sesgo donde un clasificador ingenuo puede simular un alto rendimiento sin detectar a la minoría en riesgo:

$$\text{Recall} = \frac{TP}{TP + FN}$$

1.3 Análisis Exploratorio de Datos (EDA) y Verificación de Hipótesis

Se evaluaron distribuciones y matrices de correlación para testear la premisa operativa principal:

$$\text{Hipótesis Inicial: Uso_Diario_Min} \uparrow \implies P(\text{Churn} = 1) \downarrow$$

Resultado del EDA: Se confirmó una correlación negativa significativa entre el tiempo de uso diario y la tasa de abandono. Los clientes con bajo engagement mostraron la mayor probabilidad de cancelación, respaldando la construcción de variables sintéticas de costo relativo por nivel de uso.

---

2. Fase 2: Preparación, Calidad e Ingeniería de Características

2.1 Limpieza y Calidad de Datos

1. **Imputación de `Soporte_Tickets`:** Se aplicó imputación por la **Mediana** (o KNN Imputer). Al ser una variable discreta asimétrica positiva, la media distorsionaría el centro de la distribución; la mediana preserva el valor representativo sin sesgarse por valores extremos.
2. **Tratamiento de Outliers en `Edad`:** Se aplicó la técnica de *Capping* basada en el Rango Intercuartílico ($IQR = Q_3 - Q_1$), estableciendo límites válidos en $[Q_1 - 1.5IQR,\ Q_3 + 1.5IQR]$ para corregir errores de digitación sin eliminar observaciones.
3. **Corrección de Formatos en `Antiguedad_Meses`:** Conversión de tipos de datos a entero sintácticamente válido (`int64`), corrigiendo registros vacíos o con inconsistencias menores a 0.

2.2 Ingeniería de Características (Feature Engineering)

- **Costo Por Minuto (C_{min}):** Mide la eficiencia del costo relativo del servicio para el cliente en función de su consumo real acumulado en un ciclo mensual (30 días):

$$C_{min} = \frac{\text{Monto_Mensual}}{\text{Uso_Diario_Min} \times 30}$$

- **Atención Requerida (A_{req}):** Indicador binario que captura la fricción operativa crítica en soporte técnico:

$$A_{req} = \begin{cases} 1 & \text{si Soporte_Tickets} > 5 \\ 0 & \text{en otro caso} \end{cases}$$

- **Transformaciones:** Codificación *One-Hot Encoding* para variables categóricas (`Region`, `Genero`) y escalamiento estandarizado (`StandardScaler`) para las continuas:

$$z = \frac{x - \mu}{\sigma}$$

2.3 Selección de Características

Se analizaron colinealidades mediante matriz de correlación ($|r| > 0.85$) y se aplicó selección por impureza de Gini mediante un ensamble *Random Forest*, conservando únicamente las características con una importancia relativa $> 2\%$ para reducir el espacio de entradas.

---

3. Fase 3: Modelado Supervisado y Optimización de Umbral

3.1 División de Datos y Estratificación

El dataset se dividió en **80% Entrenamiento** y **20% Prueba** mediante muestreo estratificado (`StratifiedKFold` / `stratify=y`) para garantizar que la proporción de la clase minoritaria de Churn se

preserve de forma exacta en ambas particiones.

3.2 Entrenamiento, Comparación y Balanceo

Se compararon dos familias de algoritmos:

1. **Modelo Base:** Regresión Logística (interpretabilidad lineal).
2. **Modelo Ensamble:** Random Forest Classifier (captura de interacciones no lineales).

Para mitigar el desbalanceo de clases se aplicaron técnicas de balanceo sintético (**SMOTE**) en el pipeline y ponderación explícita mediante pesos de clase (`class_weight='balanced'`).

3.3 Ajuste Operativo del Umbral de Decisión (τ)

En lugar de depender del umbral probabilístico predeterminado de $\tau = 0.50$, la clasificación binaria ajusta dinámicamente el punto operativo a $\tau = 0.35$ a partir de la curva Precision-Recall:

$$\hat{y} = \begin{cases} 1 & \text{si } \hat{P}(Y=1|x) \geq 0.35 \\ 0 & \text{en otro caso} \end{cases}$$

Este ajuste maximiza el **Recall**, logrando capturar un mayor número de Falsos Negativos a un costo marginal mínimo de Falsos Positivos.

---

4. Fase 4: Modelado No Supervisado y Estrategia Prescriptiva

4.1 Agrupamiento (K-Means) y Selección de K Óptimo

Se aplicó el algoritmo K-Means sobre las variables cuantitativas escaladas. La selección del número óptimo de segmentos ($K = 3$) se fundamentó matemáticamente en la minimización de la Inercia intra-cluster (J) mediante el **Método del Codo** y la maximización del **Coeficiente de Silueta**:

$$J = \sum_{k=1}^{K} \sum_{x_i \in C_k} ||x_i - \mu_k||^2$$

4.2 Caracterización y Acciones Prescriptivas por Cluster

Cluster	Tipología de Cliente	Características Principales	Acción Prescriptiva Recomendada
Cluster 0	*Usuarios Saludables*	Alto consumo diario, bajo volumen de soporte.	Plan de fidelización y renovación orgánica.
Cluster 1	*Riesgo por Fricción de Soporte*	Soporte acumulado (> 5 tickets), $A_{req} = 1$.	Asignación prioritaria de un Customer Success Manager (CSM).
Cluster 2	*Riesgo por Bajo Retorno (C_{min} Alto)*	Bajo uso diario respecto a la tarifa contratada.	Programa de onboarding, capacitación y re-engagement de uso.

---

5. Fase 5: Explicabilidad (XAI), Ética, Privacidad y Despliegue

5.1 Explicabilidad mediante Valores SHAP

Basado en teoría de juegos cooperativos, se calcula el aporte marginal de cada variable (ϕ_i) para explicar las predicciones globales e individuales:

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} \Big(f(S \cup \{i\}) - f(S) \Big)$$

- **Factores Globales Dominantes:** 1) Costo Por Minuto (C_{min}), 2) Tickets de Soporte, 3) Uso Diario en Minutos.

5.2 Evaluación Ética, Governance y GDPR

- **Auditoría de Equidad (Fairness Audit):** Se evalúa la paridad en el rendimiento del modelo a través de variables protegidas (`Region` y `Genero`), exigiendo una Disparidad de Recall ≥ 0.80:

$$\text{Disparidad de Recall} = \frac{\text{Recall}_{\text{grupo}}}{\text{Recall}_{\text{global}}}$$

- **Privacidad y Cumplimiento Normativo:** Cumplimiento con marcos regulatorios GDPR y leyes de Protección de Datos Personales. La aplicación no almacena ni expone PII (*Personally Identifiable Information*); la inferencia se realiza exclusivamente con parámetros numéricos anónimos.

5.3 Arquitectura de Software y Producto Final

El modelo fue empaquetado mediante `run_pipeline.py` generando artefactos serializados (`.joblib`), e integrado en una interfaz web en **Streamlit** en modo oscuro (*Dark Mode*) que ejecuta diagnósticos en tiempo real, asignación de perfil prescriptivo y soporte para la toma de decisiones humanas.